

SuperBizAgent 系统总览

普通 Chat 保持轻量只读；所有事故调用汇入单一 Durable Incident Runtime，共享工具治理、审批、证据、审计与 Checkpoint。

1. 访问与 FastAPI 接入层

Web 控制台 / API 调用方

聊天、Incident 配置、审批卡片、REST / SSE

FastAPI App + lifespan

/api/chat | /api/upload | /api/aiops | /api/enterprise/incidents | /api/incidents/{id}

2. 业务入口

RagAgentService

独立普通 Chat / RAG；MemorySaver 会话

知识入库

文档切分 -> Embedding -> Milvus

AIOpsService

单一 Durable Incident Runtime；一张持久化 LangGraph

3. 统一 Incident 父图：Simple / Enterprise 双策略自动路由

Incident Router

确定性规则 + 显式策略覆盖

Simple

Planner / Executor / Replanner / Evidence Assessor

动态升级

Auto 且证据不足时 Simple -> Enterprise；最多一次

Enterprise

Triage / RAG / SRE / Change / RCA / Remediation / Report

IncidentState v2

路由历史、证据、工具审计、报告与 SSE 事件

4. 工具接入与治理边界

Chat Read-only Tool Binding

只读 allowlist；不暴露 restart_service 等处置工具

Simple / Enterprise Tool Calls

事故策略不直连 Provider

Tool Gateway Factory

为每次节点调用创建隔离实例

Tool Gateway Instance

Identity / Risk / Policy / Approval / Timeout / Audit

普通 Chat 可使用本地只读工具和 MCP 只读子集，但不承担生产处置。

Tool Catalog / Registration Contract

LangChain BaseTool / StructuredTool；本地注册 + MCP 动态发现；下方只是当前示例，不是工具上限

本地只读工具（可扩展）

知识检索 / 时间 / 指标 / 变更查询

受控处置工具

restart_service：经 Gateway 审批，始终强制 dry-run

MCP 动态工具（可扩展）

日志 / 指标 / 变更 / CMDB / 云平台 / 工单等外部 Provider

Gateway 是治理边界，不是固定工具清单；每次调用统一沉淀 Evidence / Citations / Tool Audit / Policy Decision / Provider Failure。

5. 模型、知识与持久化边界

DashScope / Qwen

Chat、Simple 与 Enterprise 的模型 Provider

Milvus

普通 RAG + Hybrid Retrieval 向量检索

Runbook + Incident Graph

确定性 Registry 与版本化快照

MemorySaver + localStorage

普通 Chat 进程内状态 + 浏览器展示历史

LangGraph Checkpointer

PostgreSQL 持久化 Incident 父图；支持审批中断与恢复

○ 只读 / 轻量链路 ○ 安全治理边界 ○ 受控处置 ○ 持久化状态